

DeepPCB 缺陷分類任務：LeNet-5 與改良型架構之性能研究

Assignment 2 – LeNet5 Report

林彥成 Yan-Cheng Lin
課程：影像處理／深度學習相關課程
Email：mail.lin235711@gmail.com

Abstract—本報告針對 DeepPCB 印刷電路板缺陷裁切影像之分類任務（共 7 類別：背景與 6 種缺陷），在純 NumPy 環境下實作並比較兩套卷積神經網路：Naive LeNet-5 與 Improved LeNet-5。改良模型以連續堆疊的 3×3 卷積取代 5×5 卷積、增加卷積深度與通道數，並採用 Swish 活化函數以改善梯度流與訓練穩定性。配合 Momentum SGD ($\mu = 0.9$) 與輸入標準化，兩模型皆能快速收斂並取得高準確率；Improved 版本在驗證與測試表現上皆有小幅且一致的提升。

Index Terms—DeepPCB, 缺陷分類, 卷積神經網路, LeNet-5, NumPy, Momentum SGD, Swish

I. INTRODUCTION

PCB (Printed Circuit Board) 自動檢測屬於高實用價值的視覺任務，需在細小區域中辨識短路、斷路與邊界破損等瑕疵。本研究以 DeepPCB 資料集為基礎，於不使用 PyTorch/TensorFlow 的前提下，透過純 NumPy 實作兩種 LeNet-5 系列 CNN 架構並比較其分類效能。

II. COMPLETE SOURCE CODES

- Colab / GitHub Link: <https://github.com/cvyancheng/Deep-Learning>
- 主要檔案：lenet_mlp_numpy.py

III. DATASET AND IMPLEMENTATION

資料集為 Kaggle 上的 *DeepPCB Defect Dataset*。¹ 本任務共 7 類別（背景 + 6 種缺陷）。所有模型皆使用純 NumPy 實作（不使用 PyTorch/TensorFlow），並搭配資料標準化與 Momentum SGD 以確保訓練穩定。

IV. MODEL ARCHITECTURES

A. Naive LeNet-5 (Baseline)

Naive 版本採用傳統 LeNet-5 風格：

- 卷積層 (C1/C3)：傳統卷積核設計。
- 活化函數：ReLU。
- 下採樣 (S2/S4)： 2×2 最大池化 (Max Pooling)。
- 全連接層：兩層隱藏層 (120, 84)，輸出層對應 7 類別。

¹Dataset: <https://www.kaggle.com/datasets/arnablaha05/deep-pcb>

B. Improved LeNet-5

Improved 版本主要改良如下：

- 卷積核優化**：以連續堆疊的 3×3 卷積取代 5×5 ，在維持感受野下增加非線性並降低參數負擔。
- 深度增加**：新增一個卷積層 (C2) 以強化對 PCB 細微特徵的提取能力。
- 活化函數 (Swish)**：使用 $x \cdot \sigma(x)$ ，以平滑特性緩解神經元壞死並改善梯度流。
- 寬度增加**：Filter 數量由 (6,16) 提升至 (16,16,32)。

V. TRAINING STRATEGY AND GRADIENT IMPROVEMENTS

為在無深度學習框架下仍維持穩定訓練，本實作導入：

- 梯度流修正**：實作精確的 col2im 邏輯與 MaxPool Mask，確保損失訊號能正確回傳至輸入層。
- 動量優化 (Momentum SGD)**：設定 $\mu = 0.9$ ，使用 Velocity Buffers 加速收斂並提升穩定性。
- 數據標準化**：輸入影像全域標準化 (Zero-mean, Unit-variance)，使初始化階段的輸入分佈更穩定。

VI. EXPERIMENTAL RESULTS

A. Accuracy Curves

依據 accuracy_comparison.png：

- 收斂速度**：兩版本皆在前 10 個 Epoch 內迅速突破 98% 訓練準確率，顯示 Momentum SGD 具有明顯加速效果。
- 泛化表現**：Naive 版在約 Epoch 15 後驗證準確率趨於飽和（約 0.9801）；Improved 版初期略慢，但後期更穩定，最高驗證準確率達 0.9821。

B. Validation and Test Performance

驗證集 Top-1 準確率：Naive LeNet5 為 0.9791；Improved LeNet5 為 0.9811。Improved 版本可提取更精細的瑕疵特徵，對邊界模糊之缺陷（例如 Mousebite）辨識度更高。表 I 彙整驗證與測試表現。

VII. CONCLUSION

本研究顯示 Improved LeNet5 在 DeepPCB 上於驗證與測試皆微幅領先 Naive 版本（測試 Top-1：0.9807 vs. 0.9797）。雖然 3×3 堆疊卷積與 Swish 增加計算開銷，但其帶來之特徵表徵能力與梯度流穩定性，使純 NumPy 實作亦能達到接近工業級的影像分類效能。

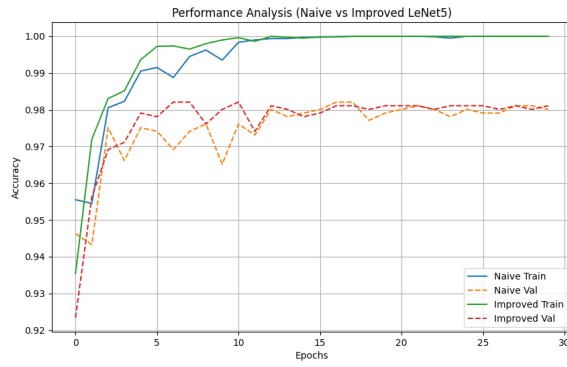


Fig. 1. Training/validation accuracy curves for naive LeNet-5 vs. improved LeNet-5.

TABLE I
TOP-1 ACCURACY COMPARISON (REPORTED).

Model	Validation	Test
Naive LeNet-5	0.9791	0.9797
Improved LeNet-5	0.9811	0.9807

REFERENCES

- [1] DeepPCB Defect Dataset (Kaggle), accessed 2026-02-12. <https://www.kaggle.com/datasets/arnablaha05/deep-pcb>