

多任務 PCB 瑕疵檢測模型訓練診斷報告

Assignment 4: Multi-Task Learning Analysis Report

林彥成 Yan-Cheng Lin
課程：影像處理／深度學習相關課程
Email：mail.lin235711@gmail.com

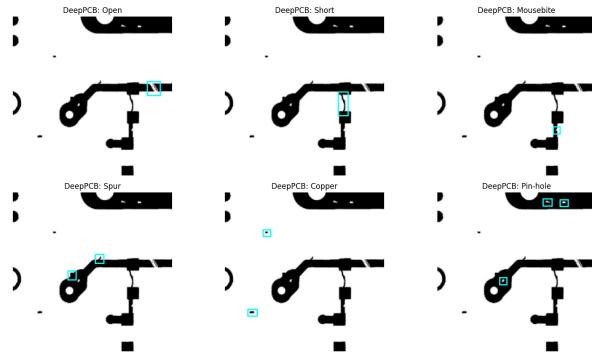


Fig. 1. DeepPCB 資料集示例。

Abstract—本報告探討多任務學習 (Multi-Task Learning, MTL) 在印刷電路板 (PCB) 瑕疵檢測上的應用與挑戰。實驗整合兩個性質差異顯著的任務：DeepPCB 資料集的目標偵測 (Object Detection) 與 VisA PCB 子集的語意分割 (Semantic Segmentation)。透過共享 ResNet-18 編碼器與雙解碼頭 (偵測頭與 U-Net 分割頭)，並採用雙階段訓練 (先分割預熱、再聯合訓練)，觀察到偵測任務在聯合訓練階段出現梯度支配 (Gradient Domination)，進而導致分割任務的負遷移 (Negative Transfer) 與效能回落。報告整理模型設計、資料預處理、學習曲線、測試結果與改進建議，並指出硬參數共享在強烈 Domain Gap 下的限制，建議後續採特徵解耦或使用 PCGrad 等方法緩解任務衝突。

Index Terms—多任務學習，PCB 瑕疵檢測，目標偵測，語意分割，負遷移，梯度支配

I. 前言

本實驗旨在探討「多任務學習 (Multi-Task Learning, MTL)」架構在印刷電路板 (PCB) 瑕疵檢測中的應用與挑戰。實驗整合了兩個性質迥異的任務：針對 DeepPCB 資料集的目標偵測 (Object Detection) 與針對 VisA 資料集的語意分割 (Semantic Segmentation)。

透過共用卷積神經網路 (CNN) 提取特徵，我們期望模型能學習到更泛化的瑕疵表徵。然而，由於兩組資料集在影像域 (Domain) 上的巨大差異 (二值化簡圖 vs. 真實彩色照片)，以及任務本身優化難度的不對稱性，本報告將剖析訓練過程中的「梯度支配 (Gradient Domination)」與「負遷移 (Negative Transfer)」現象，並提出架構上的改進建議。

II. 原始碼連結與主要檔案

GitHub Link: <https://github.com/cvyancheng/Deep-Learning-PCB>
主要檔案：

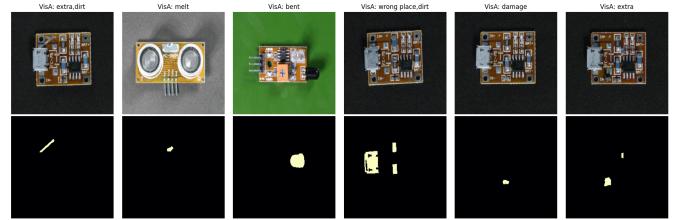


Fig. 2. VisA 資料集 (PCB 子集) 示例。

- `pcb_multi_task.py`：核心實驗代碼（資料前處理、模型 MultiTaskResUNet18、FocalDiceLoss、雙階段訓練流程）。

III. 模型實作

A. 模型架構：*MultiTaskResUNet18*

本實驗採用硬參數共享 (Hard Parameter Sharing)，建構基於 ResNet-18 的雙頭網路：

- **共享編碼器 (Shared Encoder)**：使用預訓練 ResNet-18(移除全連接層)作為主幹網路 (Backbone)，提取共用特徵 (Layer 1~4)。
- **偵測頭 (Detection Head)**：接續 Layer 4 特徵圖，透過 3×3 與 1×1 卷積輸出 8×8 的 Grid Detection 結果，負責 DeepPCB 瑕疵定位。
- **分割頭 (Segmentation Head)**：採 U-Net 解碼器，將 Layer 4 特徵透過跳接 (Skip Connections) 與 Layer 1~3 淺層特徵融合，逐步上採樣至 256×256 解析度，負責 VisA 像素級分割。

B. 損失函數與訓練策略

損失函數：

- 偵測任務：BCEWithLogitsLoss。
- 分割任務：FocalDiceLoss (結合 Focal Loss 與 Dice Loss)。

雙階段訓練：

- Phase 1 (Epoch 1–10)：凍結 Backbone，僅訓練分割解碼器 (Segmentation Warmup)。
- Phase 2 (Epoch 11–25)：解凍全網，聯合訓練 (Joint Training)。

IV. 影像特徵提取與預處理

本實驗面臨的核心挑戰為輸入資料的極端領域差異：DeepPCB：高對比、近乎二值化的線路佈局，幾何規律強、背景單純。

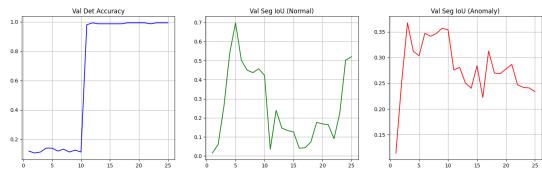


Fig. 3. 雙階段訓練之學習曲線。

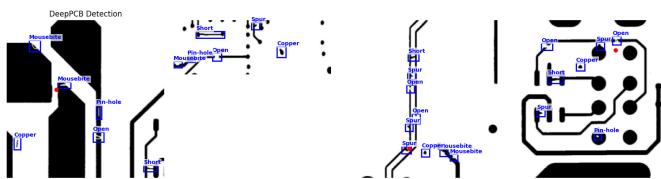


Fig. 4. DeepPCB 偵測結果視覺化。

- VisA：真實拍攝 PCBA 彩色照片，光影、反光與元件紋理複雜。

預處理流程：

- 1) 尺寸統一：所有輸入調整為 256×256 。
 - 2) 標準化：使用 ImageNet 統計量 (Mean: [0.485, 0.456, 0.406] ; Std: [0.229, 0.224, 0.225])。
 - 3) Mask 二值化：對 VisA 分割標籤閾值化，確保 Ground Truth 為 0/1。
 - 4) 過採樣：使用 WeightedRandomSampler 緩解 VisA 正負樣本不平衡，避免全背景預測。

V. 學習曲線

圖 3 顯示任務間交互作用：預熱階段（Epoch 1–10）分割 IoU 穩定上升；但進入聯合訓練（Epoch 11 之後）偵測準確率快速飆升並維持高檔，同時分割 IoU 出現震盪與回落，反映偵測任務的強梯度主導共享特徵更新，抑制分割所需的細緻高頻特徵。

VI. 測試集預測結果

A. 定量評估

最終測試集的任務效能呈現不對稱：

- Task A (DeepPCB 偵測) : Accuracy = 0.9933。
 - Task B (VisA 分割) : IoU (Normal/Background) = 0.4851 ; IoU (Anomaly/Defect) = 0.2363。

B. 定性視覺化

如圖 4，偵測任務能精準定位多類瑕疵且誤報低；相較之下，圖 5 的分割輪廓仍粗糙且不連續，顯示空間解析能力在聯合訓練中受壓抑。

VII. 結論與未來工作

本實驗驗證多任務 ResNet18-UNet 架構在異質資料集上的行為特徵，主要觀察如下：

- 1) **梯度支配**: 偵測任務 (DeepPCB) 因特徵較簡單，優化速度快，導致共享參數更新偏向偵測。
 - 2) **負遷移**: 聯合訓練未帶來協同效應，反而使分割效能低於預熱階段峰值。

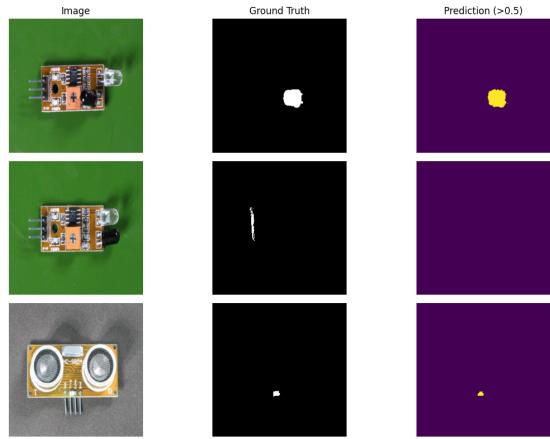


Fig. 5. VisA 分割結果視覺化。

- 3) 架構限制：硬參數共享在強 Domain Gap 的任務組合下並不理想。

改進建議：可採特徵解耦（Feature Decoupling）（例如淺層分岔、深層共享）或引入 PCGrad 等衝突梯度抑制策略，以降低任務間的破壞性干擾。